

node2vec

Graphs in the Real World


1. SOCIAL NETWORK (FACEBOOK)



1. SOCIAL NETWORK (FACEBOOK)

Node: User, Edge: Friendship


2. BIOLOGICAL NETWORK (PPI)



2. BIOLOGICAL NETWORK (PPI)

Node: Protein, Edge: Interaction


3. COLLABORATION NETWORK (arXiv)





3. COLLABORATION NETWORK (arXiv)

Node: Paper, Edge: Collaboration

그래프 분석의 목적




ANALYSIS



ANALYZED GRAPH
(COMMUNITIES DETECTED)




LINK PREDICTION



Predict Missing Edges

NODE CLASSIFICATION




Predict Node Labels


기존 그래프 분석 방법들

모델명	작동 방식 (Method)	문제점 (Limitations)
Spectral Clustering	인접행렬 + 고유값 분해	<u>이웃의 정의가 제한적임</u>
LINE	1차(직접 연결) + 2차(공통 이웃) 연결 학습	
DeepWalk	노드별 랜덤 워크	


이웃의 종류

	
Homophily(동질성)	structural equivalence(구조적 동등성)
나랑 같은 집단에 속하는가?	나랑 역할이 유사한가?

노드의 구조적 특징




구조적 역할 : BFS-like 탐색




동질성(Homophily) : DFS-like 탐색


Group A



Group B




How to implement



$$\alpha_{pq}(t, x) = \begin{cases} \frac{1}{p} & \text{if } d_{tx} = 0 \\ 1 & \text{if } d_{tx} = 1 \\ \frac{1}{q} & \text{if } d_{tx} = 2 \end{cases}$$

거리	경로의 의미 (Meaning)	가중치 (α)
 $d_{tx} = 0$	원점 회귀: 직전 노드 t로 다시 돌아가는 경로	1/p
 $d_{tx} = 1$	주변 탐색: t와 v의 공통 이웃으로 이동하는 경로	1
 $d_{tx} = 2$	영역 확장: t와 연결되지 않은 새로운 노드로 나가는 경로	1/q


q : in-out parameter



$$\alpha_{pq}(t, x) = \begin{cases} \frac{1}{p} & \text{if } d_{tx} = 0 \\ 1 & \text{if } d_{tx} = 1 \\ \frac{1}{q} & \text{if } d_{tx} = 2 \end{cases}$$

q 값의 범위	이동 방향의 특징	탐색 방식	포착하는 그래프 성질
$q > 1$	이전 노드와 가까운 곳으로 이동	BFS 방식 (주변 탐색)	구조적 동등성 (역할)
$q < 1$	이전 노드와 먼 곳으로 이동	DFS 방식 (멀리 탐색)	동질성 (소속 그룹)

p : return parameter



$$\alpha_{pq}(t, x) = \begin{cases} \frac{1}{p} & \text{if } d_{tx} = 0 \\ 1 & \text{if } d_{tx} = 1 \\ \frac{1}{q} & \text{if } d_{tx} = 2 \end{cases}$$

p 값의 설정	탐색 성향	주요 효과	학습되는 특징
$p < 1$	돌아가려는 성향 강화	시작 노드 주변을 촘촘하게 탐색	구조적 동등성 (노드의 역할)
$p > 1$	돌아가려는 성향 약화	2-hop 중복을 피하며 새로운 노드 탐색	탐색 효율성 및 집단 정보

p와 q 파라미터 정리

파라미터	역할	설정에 따른 효과	목표
p (Return)	이전 노드로 돌아갈지를 제어	Low p: 이전 노드로 회귀 (Local) High p: 중복 방문 억제 (Exploration)	탐색의 밀도와 신선도
q (In-out)	멀리 갈지, 근처로 갈지를 제어	Low q: 외부 확장 (DFS-like) High q: 내부 집중 (BFS-like)	동질성 vs 구조적 역할


Node2vec을 사용한 그래프 임베딩 과정

Algorithm 1 The *node2vec* algorithm.

LearnFeatures (Graph $G = (V, E, W)$, Dimensions d , Walks per node r , Walk length l , Context size k , Return p , In-out q)
 $\pi = \text{PreprocessModifiedWeights}(G, p, q)$
 $G' = (V, E, \pi)$
 Initialize *walks* to Empty
 for $iter = 1$ **to** r **do**
 for all nodes $u \in V$ **do**
 $walk = \text{node2vecWalk}(G', u, l)$
 Append $walk$ to *walks*
 $f = \text{StochasticGradientDescent}(k, d, walks)$
 return f

1. 하이퍼 파라미터를 설정
2. Walk를 통해 노드 시퀀스 생성
3. 노드 임베딩 값 조정

1. 하이퍼파라미터 설정




$$u = [1, 2, 3]$$

$$s_1 = [2, 3, 4]$$

...

하이퍼파라미터	의미	예시값
d	임베딩 차원	3
r	노드당 walk 수	2
l	Walk 길이	4
k	Context size	1
p	Return 비율	0.5
q	In-out 비율	4

2. 편향된 Walk를 통해 노드 시퀀스 생성




Walk1 = $[u, s_1, u, s_2, u]$

Walk2 = $[u, s_3, u, s_2, u]$

.....

하이퍼파라미터	의미	예시값
d	임베딩 차원	3
r	노드당 walk 수	2
l	Walk 길이	5
k	Context size	1
p	Return 파라미터	0.5
q	In-out 파라미터	4

3. 임베딩 값 조정




$$\text{Walk1} = [\underbrace{u, s_1, u, s_2, u}_{k=1}]$$

(u, s_1)

하이퍼파라미터	의미	예시값
d	임베딩 차원	3
r	노드당 walk 수	2
l	Walk 길이	5
k	Context size	1
p	Return 파라미터	0.5
q	In-out 파라미터	4

3. 임베딩 값 조정



$$\text{Walk1} = [\underbrace{u, s_1, u, s_2, u}_{k=1}]$$

$(u, s_1), (s_1, u), (s_1, u) \dots \dots$

하이퍼파라미터	의미	예시값
d	임베딩 차원	3
r	노드당 walk 수	2
l	Walk 길이	5
k	Context size	2
p	Return 파라미터	0.5
q	In-out 파라미터	4

3. 임베딩 값 조정

Positive sample : $(u, s_1), (s_1, u), (s_1, u) \dots$

목적 함수 :
$$\max_f \sum_{u \in V} \left[-\log Z_u + \sum_{n_i \in N_S(u)} f(n_i) \cdot f(u) \right]$$

그렇지 않은 노드 쌍들은
네거티브 샘플링으로 작게

노드 쌍으로 나온 값들은 크게

Experiment - setup

- 비교 대상 알고리즘
 - Spectral Clustering
 - DeepWalk
 - LINE
- 공정성
 - 총 샘플 수 K 값을 동일하게 맞춤 ($K = r \cdot l \cdot |V|$)
 - DeepWalk의 Hierarchical Softmax 대신 Negative Sampling 적용
 - 모든 실험에서 하이퍼파라미터 고정
 - p, q 값은 $\{0.25, 0.50, 1, 2, 4\}$ 중 그리드 서치
 - 랜덤 시드로 10번 반복

Experiment - Dataset

- Blog catalog
 - 블로그 사이트의 사회적 관계망
 - Node(10,312) : 블로거
 - Edge(333,983) : 친구 관계
- PPI
 - 단백질 상호작용 네트워크
 - Node(3,890) : 단백질
 - Edge(76,584) : 단백질간 생물학적 상호작용
- Wikipedia
 - 위키에서 추출한 단어들 간의 관계
 - Node(4,777) : 단어
 - Edge(184,812) : 일정 거리 내에 두 단어가 동시 등장

Experiment Result : Multi-label classification

Algorithm	Dataset		
	BlogCatalog	PPI	Wikipedia
Spectral Clustering	0.0405	0.0681	0.0395
DeepWalk	0.2110	0.1768	0.1274
LINE	0.0784	0.1447	0.1164
<i>node2vec</i>	0.2581	0.1791	0.1552
<i>node2vec</i> settings (p,q)	0.25, 0.25	4, 1	4, 0.5
Gain of <i>node2vec</i> [%]	22.3	1.3	21.8

Experiment Result : Multi-label classification







Figure 4: Performance evaluation of different benchmarks on varying the amount of labeled data used for training. The x axis denotes the fraction of labeled data, whereas the y axis in the top and bottom rows denote the Micro-F₁ and Macro-F₁ scores respectively. DeepWalk and *node2vec* give comparable performance on PPI. In all other networks, across all fractions of labeled data *node2vec* performs best.

Experiment Result : link prediciton

Operator	Symbol	Definition
Average	$\boxplus$	$[f(u) \boxplus f(v)]_i = \frac{f_i(u) + f_i(v)}{2}$
Hadamard	$\boxdot$	$[f(u) \boxdot f(v)]_i = f_i(u) * f_i(v)$
Weighted-L1	$\ \cdot\ _{\bar{1}}$	$\ f(u) \cdot f(v)\ _{\bar{1}i} = f_i(u) - f_i(v) $
Weighted-L2	$\ \cdot\ _{\bar{2}}$	$\ f(u) \cdot f(v)\ _{\bar{2}i} = f_i(u) - f_i(v) ^2$

Op	Algorithm	Dataset		
		Facebook	PPI	arXiv
	Common Neighbors	0.8100	0.7142	0.8153
	Jaccard's Coefficient	0.8880	0.7018	0.8067
	Adamic-Adar	0.8289	0.7126	0.8315
	Pref. Attachment	0.7137	0.6670	0.6996
(a)	Spectral Clustering	0.5960	0.6588	0.5812
	DeepWalk	0.7238	0.6923	0.7066
	LINE	0.7029	0.6330	0.6516
	node2vec	0.7266	0.7543	0.7221
(b)	Spectral Clustering	0.6192	0.4920	0.5740
	DeepWalk	0.9680	0.7441	0.9340
	LINE	0.9490	0.7249	0.8902
	node2vec	0.9680	0.7719	0.9366
(c)	Spectral Clustering	0.7200	0.6356	0.7099
	DeepWalk	0.9574	0.6026	0.8282
	LINE	0.9483	0.7024	0.8809
	node2vec	0.9602	0.6292	0.8468
(d)	Spectral Clustering	0.7107	0.6026	0.6765
	DeepWalk	0.9584	0.6118	0.8305
	LINE	0.9460	0.7106	0.8862
	node2vec	0.9606	0.6236	0.8477

Experiment Result : robust and scalability



Conclusion

- 탐색 전략의 일반화 및 유연성 확보
 - p, q 파라미터를 통해 DeepWalk를 일반화 했고, 탐색방식을 BFS또는 DFS로 조절하여 그래프 특성에 맞는 최적의 이웃을 선택정으로 정의할 수 있게 함
- 고성능 및 데이터 효율성 증명
 - 노드 분류와 링크 예측 모두 기존 모델보다 뛰어난 성능을 보임
 - 라벨 데이터가 적어도(10%) 안정적이고 높은 성능 보임
- 실무적 강건성과 선형적 확장성
 - 임의로 edge를 추가시키거나 삭제해도 성능 변화가 적음
 - 노드 수에 따라 학습시간이 선형적으로 증가함